QuantumGate：从分数拟合转向功能与任务

阶段审校报告 | 2026-10-30。功能适配、对角控制、checkpoint 重放与串行计时已完成。正文聚焦结论与设计含义，逐 seed 数据、区间和审计清单见配套补充材料。

主要结论：先改训练对象，再判断结构的适用范围

对实际参与计算的稀疏混合权重追加适配后，量子与经典 gate 对既有模型功能的保留均明显改善。三种目标共同追加相同训练预算，使误差集中到真正送入专家混合的权重上；本轮的主要对照是这些目标之间的差异，适配前 checkpoint 用于记录变化幅度。

交错 CZ 门从专家输出距离中获得收益：它对原模型输出分布的偏离在三个种子上均低于权重距离目标，其中两个种子的配对区间明确向下。对角控制取得了几乎相同的效果，说明当前收益主要来自各专家的功能尺度。模型 Fisher 目标没有稳定超越输出距离；MLP 与经典幅度门采用权重距离时已经较好地保留功能。

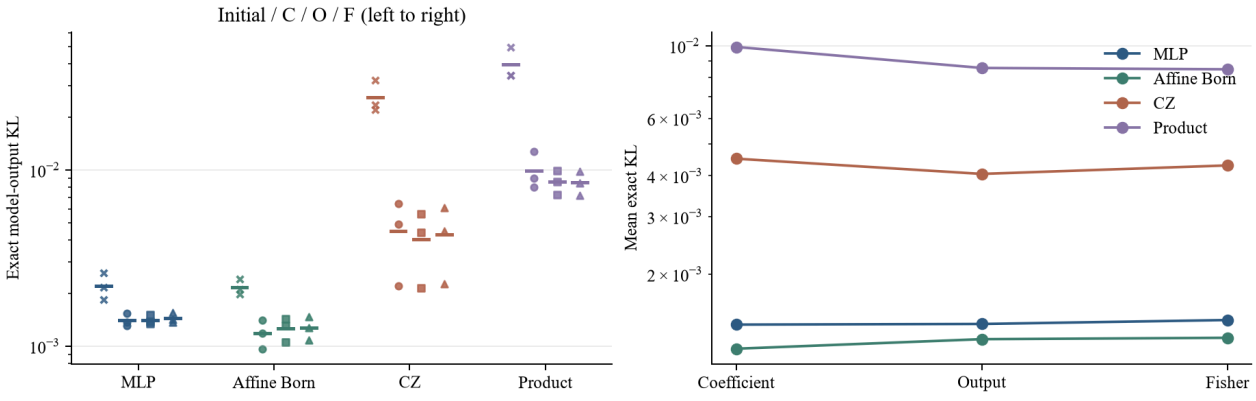


图 1　同一内部 dev 上的真实输出 KL。左图每组依次为适配前、权重距离 C、专家输出距离 O、模型 Fisher 距离 F；右图展示三种目标的均值。每种子分别保留，纵轴采用对数尺度。

这轮评价围绕一个已经训练好的经典 teacher 展开。它回答的是结构替换时如何保留现有功能。另一条独立评价路线允许 QuantumGate 与专家共同形成不同分工，直接以任务成绩、计算效率和稳定性评判；后续架构取舍需要同时纳入这条路线。

两种 **Fisher** 分别刻画模型风险与状态方向

专家输出决定“换一种混合方式会把隐藏表示推向哪里”，模型输出的 Fisher 决定“这些方向会使预测分布变化多少”。前者给出专家空间中的真实平方距离，后者对它再施加模型头的敏感度。两种几何都可以训练经典 gate 和 QuantumGate。

$$d = w - w_0, \quad G_O = V\frac{V^\top}{D}, \quad G_F = \frac{1}{2}J^\top(\mathrm{diag}(p) - pp^\top)J, \quad L = d^\top G d$$

这里 V 的各行为中心化专家输出；J 将混合系数变化映射到最终 logits，包含 LayerNorm 与词表投影。输出目标等于真实混合输出误差；Fisher 目标是原模型分布附近 KL 的二阶近似。训练只使用训练集缓存的几何与原始权重，所有目标都用内部 dev 的真实 KL 选择 checkpoint。

量子 QFI 处理另一个层次：状态对编码角度的可区分性。交错编码使完整态的有效角度方向由乘积对照的四个增加到八个。稀疏读出随后只保留四个、总和为一的混合权重，因此固定选择集合内最多有三个独立权重方向。状态表达、稀疏读出与模型功能需要分别检查。

对任意正概率分布，把各分量平方根作为实振幅，其 QFI 就等于该分布的经典 Fisher。Softmax 与 Born 在同一个概率分布上的这一度量一致；具体线路约束了可达分布族及其输入映射，这才是结构比较的对象。

一个更直接的结构线索：**top-4** 支持集的几何

对无概率地板的乘积态，选中权重的对数比由四个独立比特的 log-odds 决定。若选中的四个基态形成平行四边形，局部权重只能沿两个方向变化；一般四点单纯形允许三个方向。乘积门样本中出现了大量秩二集合，CZ 样本均为秩三。微小概率地板可把乘积门的退化方向抬升成很弱的方向；这个细节与 Jacobian 谱一起保留。

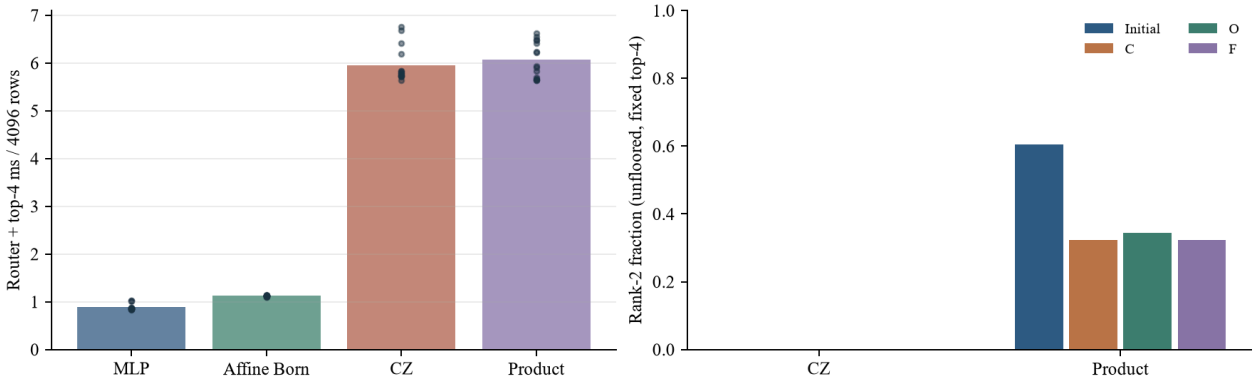


图 2　左：全部适配 checkpoint 的串行 router+top-4 计时。右：固定 top-4 下无地板权重 Jacobian 的秩二比例。右图讨论角度到权重的局部映射；跨集合选择边界需另外分析。

当前 CZ 收益主要由专家自身尺度解释

对角控制保留每个专家的功能尺度，并删除专家对之间的交叉项。它与完整几何使用相同起点、样本、训练步数、校准幂和训练集 trace 归一化。这个比较把“不同专家应该受到不同惩罚”与“专家之间的相容关系有价值”拆开。中心化专家坐标在所有控制中固定。

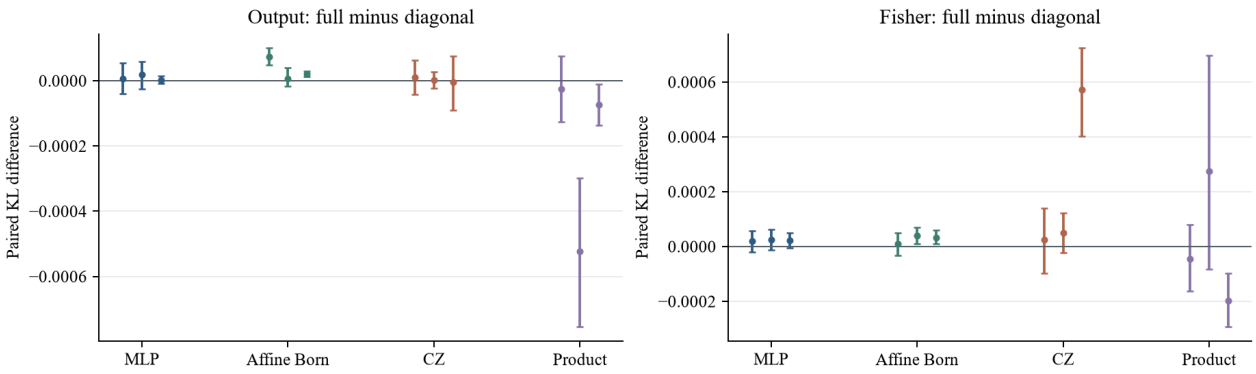


图 3　完整几何减去对应对角几何的真实 KL 配对差；每个点为一个种子，误差条为按窗口重采样的 95% 区间。负值表示完整几何保留原模型更好。

CZ 的完整输出几何与对角几何几乎重合，Fisher 对角控制的 KL 点估计在三个种子上都更低。MLP 与经典幅度门的完整交叉项也未改善内部 dev KL。乘积门的完整输出几何在三个种子上均有小幅点估计改善，表明交叉项的作用会随可达混合族而变化。现阶段优先采用功能尺度更有依据。

误差分解还显示，较小的权重误差与较低的功能敏感度可以通过不同途径降低模型偏移。跨种子平均后，乘积门在输出目标下允许略大的系数误差，同时将误差移向输出影响较小的方向。当前中心化坐标下，整体交叉项平均表现为误差放大；这一分解支持进一步检查误差方向与专家尺度的匹配。

当前预算中的实际代价

功能几何只进入训练目标，推理仍沿各自原有 router 与 top-4 路径执行。量子态模拟路径的串行耗时高于 MLP 与经典幅度门；本轮记录了适配后全部 checkpoint 的实际延迟。训练阶段另有专家输出和 Fisher Gram 的预计算成本，部署与训练的预算分开列示。

输入舍入下的稳定性比较呈混合结果。有害切换事件较少，目标和种子之间的变化方向不一致；完整计数、误差尾部、负载和未用专家均放入补充材料，后续共同适配保留这些评价项。

下一步：以任务驱动的共同分工检验 QuantumGate

后续最有价值的实验是允许 gate 与专家共同适配，再观察它们形成的分工及任务成绩。经典 teacher 模仿能力作为机制对照保留，任务损失将成为主评价。这样可以识别两类成功：较好地复现既有计算，以及通过不同路由组织形成同样好或更好的计算。

评价路径	优化与固定项	主要判据
既有功能保留（本轮）	专家与模型固定，调整 gate	真实 KL、CE、选择边界与开销
共同适配（下一阶段）	同一共享初始化，gate 与专家共同更新	等 token CE/PPL、等时间成绩、稳定性
分工机制分析	保留全部种子与预定控制	功能相似性、实际替换代价、任务条件分工

建议下一阶段预先固定 MLP、经典幅度、CZ 与乘积四组，使用相同专家初始化和采样流。先做小规模共同适配可行性检查，再以训练集内部 dev 决定是否扩大。将语义任务条件、专家激活与实际功能替换证据结合，检验任务专属算子的解释。

扩大前还应加入最接近的已有量子路由移植对照，并沿用前次新颖性核查中对公开实现与论文读出形式的区分。功能关系驱动的候选结构需要与同规模随机关系、匹配经典读出接受相同监督，形成清楚的增量比较。

已有研究与本轮工作的落点

MoE 层输出蒸馏已有直接先例；B-Distill 还联合使用 router 分布匹配、熵正则与专家探索。重复数据编码的表达性也已有系统研究。本轮值得继续追踪的问题是：怎样依据实际专家功能和稀疏边界，选择或约束量子线路的可达方向，并在同等预算的经典对照中检验它。

MoE 层输出蒸馏：原始论文

B-Distill：router 分布与专家探索

量子重复编码的表达与输入尺度研究

交付范围与下一次审校

本阶段完成了功能目标适配、交叉项控制、数学核验和推理路径计时，保留了前轮阴性结果及选择器诊断。当前测量覆盖冻结模型最后一个专家模块，在预定窗口位置重放实际前向；自然标签只用于结果报告。validation 已被观察，test 仍保留。端到端共同适配与新任务上的独立验证列为下一阶段工作。

逐 seed 结果、协议与核验补充