QuantumGate 逐节教学讲义

从路由概率到信息几何：配合研究报告阅读的例题与分析

这份讲义默认你掌握基础概率、向量、矩阵以及简单求导。重点是把这些知识连接到 QuantumGate：每个概念解决什么问题，公式中的量如何计算，实验结果怎样支持一个解释。

阅读时可以把原报告放在旁边。第 1 章对应原报告引言，第 2—4 章拆解概率与几何，第 5 章解释文献路线，第 6 章分析真实实验，第 7 章讲实验设计，第 8—9 章对应讨论与结论。文中的练习在讲义末尾附有答案。

文中“手算例”采用为教学设计的小数值；第 6 章单独标明来自 MoTE 的实测结果。两类数字分别用于理解机制和评估已有模型。首次阅读可以先看每章结论和例题，第二次阅读再跟随 Fisher 的推导。

阅读导航

1 先抓住研究问题：路由器究竟在学什么 2
2 同一个概率，为什么会有不同的训练过程 2
3 Fisher 几何：衡量模型对变化有多敏感 3
4 从连续概率到离散选择：稳定性在哪里发生 5
5 怎样读懂文献中的几条研究路线 6
6 把实际实验读成机制问题 7
7 怎样设计能回答问题的实验 9
8 讨论失败机制与资源成本 10
9 读完以后，如何回到原报告 10
10 练习答案与讲解 12
11 延伸阅读 13

1 先抓住研究问题：路由器究竟在学什么

对应原报告：第 1 节：引言

QuantumGate 要解决的核心问题，是怎样根据当前输入选择合适的专家，并给这些专家分配权重。专家承担实际计算，路由器决定调用方式。理解这种分工以后，概率参数化、遗忘和稳定性就能连成一条线。

1.1 手算例：同一个输入，三位专家怎样共同作答

教学设定中，某个输入对应三位专家的标量输出分别为 10、20、40，路由权重为 (0.6, 0.3, 0.1)。完整加权输出为 0.6×10＋0.3×20＋0.1×40＝16。实际模型的专家输出通常是向量，各坐标以同样方式组合。

若演示模型采用 top-2，并把保留的权重重新归一化，就会选中前两位专家，使用 (2/3, 1/3)，输出变成 13.33。这个例子说明，读懂路由实现需要分别检查软概率、保留的专家集合，以及选择之后的权重规则。后面的例题会明确使用哪一种规则。

1.2 为什么路由会影响学习

路由决定了专家接触哪些输入及其参与程度。长期获得相似输入的专家，容易形成相似的适应方向；一个专家的选择频率变化，会改变它后续接收的训练信号。具体更新还取决于实现中的梯度估计、辅助损失和专家结构。

由此产生三个研究问题。第一，输入到概率的函数是否容易学到有效分工？第二，新任务到来时，已有分工是否被破坏？第三，输入出现小变化时，专家选择和最终输出会改变多少？原报告的编码、持续学习和稳定性分析分别回答这三个问题。

1.3 读论文时先找这四个对象

把一个 gate 画成四个方框：输入编码 → 特征交互或态演化 → 概率读出 → 专家选择。比较两个模型时，圈出发生变化的方框。例如共享 Born 改变了演化计算方式，温度改变了权重锐度，边界损失改变了训练目标。这样可以把一个总分差异分解为具体的问题。

> 练习 **1** 三位专家仍输出 10、20、40。如果完整权重从 (0.6, 0.3, 0.1) 变为 (0.5, 0.4, 0.1)，输出改变多少？哪一项导致变化？

2 同一个概率，为什么会有不同的训练过程

对应原报告：第 2.1—2.2 节：概率空间、参数化与后处理

这一节的关键是区分两个问题：模型能输出哪些概率，以及训练时沿着怎样的路径改变这些概率。Born 读出与 softmax 可以到达同一组正概率分布，输入编码和参数化会决定到达这些分布的方式。

2.1 手算例：把同一份分工写成两种形式

继续使用 p＝(0.6, 0.3, 0.1)。一种振幅表示是 ψ＝(√0.6, √0.3, √0.1)，约为 (0.7746, 0.5477, 0.3162)。各分量平方后恢复 p，平方和为 1。另一种表示取 logits 为 log p，约为 (−0.5108, −1.2040, −2.3026)。softmax 先取指数，再除以指数和，因此同样得到 p。

$$p_i = |\psi_i|^2, \quad \psi_i = \sqrt{p_i}, \quad p = \mathrm{softmax}(\log p).$$

普通类别概率的单纯形，就是“每项非负、总和为 1”的所有向量组成的集合。三类概率可以画成一个三角形内部的点。以上两种写法说明，这个三角形内部的每一点都能用两种坐标表达。研究焦点因此落在坐标、函数结构和训练过程。

2.2 参数化具体改变了什么

参数化相当于为同一个输出选定调节旋钮。旋钮转动相同的数值，输出可能变化不同；输入经过不同结构，也可能产生不同形状的概率函数。所谓归纳偏置，就是结构使某些函数更容易表达或学到。

2.3 手算例：同样预测 **10%**，两种旋钮的梯度不同

考虑一个二分类样本，正确标签为 1，损失为 L＝−log p。第一种参数化取 p＝sigmoid(z)，第二种取 p＝sin²θ。在 p＝0.1 时，z≈−2.197，θ≈0.322 弧度。对 z 求导得到 p−1＝−0.9；对 θ 求导得到 −2cotθ ＝−6。

$$\frac{\mathrm{d}L}{\mathrm{d}z} = p - 1, \quad \frac{\mathrm{d}L}{\mathrm{d}\theta} = -2\cot\theta.$$

两种参数的数值单位与对概率的灵敏度不同。因此，相同学习率会产生不同的概率更新幅度。比较训练效率时，需要调优各自学习率，或者直接比较更新后的概率变化。Fisher 度量将在下一章为这种比较提供统一尺度。

2.4 平方归一化为什么需要一个简单基线

若编码器输出 a＝(3, 2, 1)，平方归一化给出 (9/14, 4/14, 1/14)。也可以先把 2log|a| 当作 logits，再做 softmax。这个等式允许我们构造一个很干净的消融：相同编码器只使用平方读出，随后再加入演化层，测量后者的增量贡献。

$$p_i = \frac{a_i^2}{\sum_j a_j^2} = \mathrm{softmax}\left(2\log|a|\right)_i.$$

2.5 手算例：温度会把同一分布变得更尖

先忽略很小的概率平滑。将 p＝(0.6, 0.3, 0.1) 的每个分量平方再归一化，得到 (0.7826, 0.1957, 0.0217)。第一位专家的份额从 60% 上升到约 78%。在报告的写法中，这对应增益与温度之比 g/T ＝2。

$$w_i = \frac{p_i^{\alpha}}{\sum_j p_j^{\alpha}}, \quad \alpha = \frac{g}{T}.$$

当 α＞1 时，高概率项被强化；当 0＜α＜1 时，分布更平缓。固定正 α 会保留原概率的排序，所以对一份固定输入，top-k 集合保持相同；权重大小、梯度和后续训练路径随之变化。研究稳定性时，还需要观察不同输入附近的分数变化。

本章回到原报告的结论是：先统一编码器和输出锐度，再比较平方读出、旋转、耦合和重上传。这样，一次结果变化才对应一个可定位的组件。

练习 **2** p＝(0.8, 0.2) 在 α＝2 时变成什么？top-1 会改变吗？

3 Fisher 几何：衡量模型对变化有多敏感

对应原报告：第 2.3—2.4 节：相位、测量信息与实振幅 Fisher 等价

Fisher 信息回答一个很实用的问题：参数改动一点，输出分布会改变多少？“几何”在这里表示参数空间中的距离应怎样计算。距离可以依据参数数值，也可以依据这些参数对预测的影响。

3.1 手算例：相同概率背后可以保存不同相位

两个实态 ψ₊＝(1, 1)/√2 和 ψ₋＝(1, −1)/√2 的平方概率都是 (1/2, 1/2)。给它们施加同一个 Hadamard 矩阵 H，结果分别是 (1, 0) 和 (0, 1)。原先藏在正负号中的相对相位，通过混合变成了完全不同的读出概率。

$$H = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad H\psi_+ = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad H\psi_- = \begin{pmatrix} 0 \\ 1 \end{pmatrix}.$$

这个例子解释了报告中“相位是否可观测”的含义。相位的作用取决于读出前如何混合振幅。测试一个复振幅 gate 时，可以追踪相位参数经过全部演化后对输出概率的导数。导数较大的方向实际参与了当前路由。

3.2 先从一个硬币分布理解 Fisher

设分布为 (p, 1−p)，把 p 本身当作参数。Fisher 信息为 1/[p(1−p)]。在 p＝0.5 时它等于 4，在 p＝0.01 时约为 101.01。相同的极小 Δp，在很少出现的事件附近会造成更大的相对变化，因此获得更高的几何权重。

$$F(p) = \frac{1}{p(1-p)}, \quad D_{\mathrm{KL}}(p \,\|\, p+\delta p) \approx \frac{1}{2} F(p)(\delta p)^2.$$

这里 KL 比较的是两个二项分布，公式采用小变化的二阶近似。取 Δp＝0.0001，在 p＝0.5 附近得到约 2×10^{-8}，在 p＝0.01 附近得到约 5.05×10^{-7}。两者相差约 25 倍。Fisher 把“同样大小的参数步长”换算成“对预测影响相近的步长”。

3.3 多参数时，Fisher 成为一个矩阵

设参数为 θ_1、θ_2、……。某些参数可以互相抵消，另一些组合会共同放大输出变化，因此需要矩阵同时记录各方向与方向之间的耦合。经典 Fisher 的元素是各输出概率导数乘积的加权和：

$$F_{ab} = \sum_i \frac{(\partial_a p_i)(\partial_b p_i)}{p_i}.$$

下标 a、b 对应两个参数方向，i 遍历类别。对任意小步长 Δθ，二次型 $\Delta\theta^{\mathrm{T}} F \Delta\theta$ 近似描述分布变化的大小。矩阵的大特征值方向对预测更敏感，小特征值方向的局部影响更弱。

3.4 手算例：自然梯度怎样调整两个更新方向

设普通梯度为 (0.1, 0.1)，Fisher 为 diag(100, 1)。普通梯度下降对两个坐标使用相同更新量；用 F^{-1} 修正后，方向变为 (0.001, 0.1)。第一方向对分布敏感，更新被缩小。实际求解常加入 λI，使接近零的特征值保持可处理。

$$\delta\theta = -\eta (F + \lambda I)^{-1} \nabla L.$$

“自然”指使用与模型输出相关的度量。一次更新还包含构造 F 和求解线性系统的成本，实际收益应通过达到目标质量所需的总时间衡量。

3.5 为什么实振幅的两种 Fisher 恰好相等

从 $p_i = \psi_i^2$ 开始，对参数 θ_a 求导得到 $\partial_a p_i = 2\psi_i \partial_a \psi_i$。把它代入上一式，分子中出现 $4\psi_i^2$，分母为 ψ_i^2；在局部振幅非零处约去，得到 $4\Sigma_i \partial_a \psi_i \partial_\beta \psi_i$。

$$F^{C}_{ab} = \sum_i \frac{4\psi_i^2 (\partial_a \psi_i)(\partial_b \psi_i)}{\psi_i^2} = 4 \sum_i (\partial_a \psi_i)(\partial_b \psi_i).$$

归一化条件 $\Sigma_i \psi_i^2 = 1$ 的导数是 $\Sigma_i \psi_i \partial_a \psi_i = 0$。纯态量子 Fisher 中沿状态自身方向的项因此消失，留下的正是上述表达式。这样便得到实态联合读出下的 $F^{c} = F^{q}$。这一计算应用于平滑和温度处理之前的状态与概率；研究最终权重时，把后处理的导数继续接上。

3.6 手算例：用一个角度把等式算出来

取 $\psi(\theta) = (\cos\theta, \sin\theta)$，则 $p = (\cos^2\theta, \sin^2\theta)$。在 $\theta = \pi/6$ 时，$p = (3/4, 1/4)$，概率导数为 $(-\sqrt{3}/2, \sqrt{3}/2)$。经典 Fisher 是 (3/4)/(3/4)＋(3/4)/(1/4)＝1＋3＝4。状态导数为 $(-\sin\theta, \cos\theta)$，其平方和是 1，量子 Fisher 也等于 4。

3.7 原报告的 Fubini–Study 公式怎样读

$$\mathrm{d}s^2_{\mathrm{FS}} = \frac{1}{4} \sum_i \frac{(\mathrm{d}p_i)^2}{p_i} + \sum_i p_i \cdot (\mathrm{d}\varphi_i)^2 - \left(\sum_i p_i \, \mathrm{d}\varphi_i \right)^2.$$

把右边分成两块就容易理解。第一块是概率变化，正好带有 $1/p_i$ 的 Fisher 权重。后两项合起来是相位变化的加权方差：若所有相位都加上相同量，方差为零；若它们相对变化，就会贡献状态距离。这个公式把“输出概率变化”和“相对相位变化”放在同一张账单上。

对 QuantumGate，保护旧域专家选择时可以优先使用输出概率的 KL 或 Fisher；研究复相位与后续混合层的学习作用时，再比较完整的态度量。两种目标分别对应账单中的哪些项目，由此清楚可见。

练习 **3** 若 $\psi(\theta)=(\cos\theta, \sin\theta)$，在 $\theta=\pi/4$ 时计算经典 Fisher。把 θ 换成 $\theta=2u$ 后，关于 u 的 Fisher 是多少？

4 从连续概率到离散选择：稳定性在哪里发生

对应原报告：第 2.5 节，以及第 4.4 节的输出误差分析

稳定性需要沿计算链逐段理解：输入怎样改变分数，分数怎样改变专家集合，集合变化怎样影响输出。每一段都有自己的敏感因素。

4.1 手算例：0.01 的间隔能承受多大的分数扰动

假设 top-1 的两个领先分数是 1.00 和 0.99，间隔 $m=0.01$。如果每个分数的变化绝对值都小于 0.004，最坏情况是第一项下降 0.004、第二项上升 0.004，此时间隔仍有 0.002，选择保持不变。

若第一项下降 0.006、第二项上升 0.006，新分数就是 0.994 和 0.996，选择翻转。两项向相反方向移动，解释了公式中的因子 2。

$$\|\delta z\|_\infty < \frac{m_k}{2}, \quad m_k = z_{(k)} - z_{(k+1)}.$$

4.2 为什么只看间隔还不够完整

间隔与扰动必须采用同一尺度。如果把所有分数乘以 100，间隔会从 0.01 变成 1；同一输入扰动造成的分数变化也会乘以 100。选择的实际安全余量由两者的比例决定。实验中应同时测量 gap 和实际分数误差。

Jacobian 记录输入变化怎样传递到分数。局部近似为 $\Delta z \approx J\Delta x$。若编码器把某个输入方向放大得很强，该方向上的小扰动就能穿过选择边界。因此边界损失与 Jacobian 正则化分别作用于“边界有多远”和“输入变化被放大多少”。

4.3 共享演化改变了哪一条敏感路径

$$\mathrm{d}\psi = (\mathrm{d}U)a + U\,\mathrm{d}a, \quad \psi(x) = U(x)a(x).$$

输入相关演化有两条路径：输入改变编码 a，也改变演化 U。共享 Born 让 U 与当前输入无关，第一项变为零。训练过程中 U 仍可被优化器更新；同一次前向中的各个 token 使用共同的 U。这个区别同时解释了共享矩阵的缓存机会与敏感度分解。

4.4 手算例：一次有害切换可以超过一百次轻微切换

教学设定中，两位专家对同一输入输出 10 和 10.1，top-1 交换造成 0.1 的输出变化。换成输出 10 和 −10 的两位专家，交换造成 20 的变化。前者发生 100 次，平方误差总量为 $100\times0.1^2=1$；后者只发生 1 次，平方误差就达到 $20^2=400$。

$$\delta y = \sum_i \delta w_i f_i(x).$$

公式固定同一输入下的专家输出，专门计算权重变化的贡献。真实输入扰动还可能改变专家自身输出；多层网络继续传播这些差异。因此评估至少记录三项：切换次数、被替换专家的输出差异、最终预测误差。

4.5 怎样理解“输出敏感性加权的边界损失”

一种候选设计是：两位临界专家的输出差异较大时，对它们之间过小的分数间隔施加更高惩罚。差异较小时，惩罚可以更轻。这样训练会优先保护后果严重的边界。实现时还要计算这项额外测量的成本，并检查是否损害专家分工和任务质量。

练习 **4** 路由 A 在 1000 个样本中发生 20 次切换，每次输出变化为 0.2；路由 B 发生 2 次切换，每次变化为 3。只统计这些切换贡献时，哪一个平均平方误差更小？

5 怎样读懂文献中的几条研究路线

对应原报告：第 3 节：持续学习、编码频谱、泛化与数据污染

5.1 持续学习：新任务为什么会伤到旧任务

设旧任务和新任务使用同一组参数。新任务的下降方向可能提高旧任务损失，这就形成任务间干扰。对路由器，这种变化会表现为旧输入被分给其他专家，或相同专家的组合权重发生改变。公开量子持续学习研究采用重要参数保护来减轻这种干扰，见 量子持续学习研究 和 超导实验。

5.2 手算例：用一个参数算出 EWC 的折中点

设旧任务偏好 $\theta=0$，新任务损失为 $(\theta-2)^2/2$。直接训练新任务会选择 $\theta=2$。现在加入 $\lambda F\theta^2/2$，取 $F=9$、$\lambda=1$。总损失对 θ 的导数为 $(\theta-2)+9\theta$，令其为零，得到 $\theta=0.2$。

$$L(\theta)=\frac{1}{2}(\theta-2)^2+\lambda\frac{F}{2}\theta^2,\quad \theta^\star=\frac{2}{1+\lambda F}.$$

若用 $\theta^2/2$ 衡量旧任务损失，$\theta=2$ 时为 2，$\theta=0.2$ 时为 0.02；新任务损失分别为 0 和 1.62。保护越强，旧功能保留越多，新任务靠近自身最优点的程度越低。实验应同时记录旧任务保持与新任务学习，并绘制两者的折中曲线。这里的 $F=9$ 是教学指定的局部重要性系数。

5.3 路由保护与整个模型的遗忘

假设旧输入一直选择专家 A，路由完全保持；专家 A 的参数更新后，其输出可能从 10 变为 20。此时旧任务依然会变化。因此联合训练中要同时观察 backbone、路由器和专家。保存旧原始输入可以重新计算表征，帮助区分变化发生在哪一层。

5.4 长序列记忆与跨任务遗忘分别发生在哪里

长序列记忆追踪同一次序列计算中的信息传播。考虑线性递归 $h_t=Wh_{t-1}$：反向传播到很早的位置时会连续乘以 W 的转置。若 $W=0.9I$，经过 100 步，梯度尺度缩为 $0.9^{100}\approx0.0000266$；若 W 为正交矩阵，这段纯线性传播保持向量范数。酉或正交循环网络由此获得控制长距离梯度的结构。加入非线性后，还需要计入非线性的导数。

跨任务遗忘追踪多轮训练后同一参数的变化，EWC 处理的是这一时间尺度。当前 QuantumGate 对每个 token 独立构造状态，旧知识主要保存在模型参数中。若要研究递归记忆，需要另外引入跨 token 传播的状态，并测量长距离依赖。这两个问题分别对应计算图中的时间递归和优化过程中的任务更替。

5.5 重上传：重复输入如何产生新的频率

5.6 手算例：一次旋转与两次旋转

从状态 (1,0) 出发，一次 RY(x) 产生 $(\cos(x/2),\sin(x/2))$，第二个分量的概率是 $\sin^2(x/2)=(1-\cos x)/2$。连续施加两次相同 RY(x) 等价于 RY(2x)，概率变成 $\sin^2 x=(1-\cos 2x)/2$。输入在表达式中的频率从 1 变成 2。

$$p_1^{\mathrm{one}}(x)=\frac{1-\cos x}{2},\quad p_1^{\mathrm{two}}(x)=\frac{1-\cos(2x)}{2}.$$

加入不同轴的旋转、可学习角度和耦合后，函数结构会更丰富。若任务需要周期变化，或某些交互可以被这类频率有效描述，重上传就提供了相关结构。对应的经典对照是使用相同输入编码的正弦/余弦特征网络。详见 编码与表达能力分析。

5.7 对称性与专家编号：先验究竟施加在哪里

结构先验会优先表达某些输入关系。例如，一个任务的输出对两个对象交换位置保持相同，可以让模型直接对称地处理这两个输入，从而减少需要数据重新学会的关系。对 QuantumGate，还要检查线路中 qubit 的邻接关系怎样映射到专家编号。

5.8 手算例：换一套编号，物理问题是否还相同

四位专家编号为 00、01、10、11 时，只翻转末位的操作连接 00↔01 和 10↔11。若把编号 01 与 10 对应的专家整体交换，同样的线路会连接不同的实际专家。实验可同步置换专家权重和路由输出坐标，再比较不同编号下的训练结果。跨编号重复的收益说明结构较少依赖某次布局；收益随布局大幅改变，则需要研究专家组织与耦合图的匹配。

5.9 有效维度：参数是否在做重复的工作

想象两个参数只通过 $\theta_1+\theta_2$ 影响输出。沿 $(1,-1)$ 方向移动时，两者相互抵消，预测保持相同；沿 $(1,1)$ 方向移动时，预测变化明显。这个模型有两个参数，却只有一个局部有效方向。Fisher 的特征值可以帮助识别这样的冗余。

增加线路深度后，应检查新增方向是否帮助降低验证损失。如果有效秩增加同时训练更难、验证结果更差，就需要分析容量、噪声拟合或优化代价。学习问题的价值取决于数据需要哪些方向，见 数据相关量子 Fisher 研究。

5.10 算法稳定性与输入稳定性使用不同的扰动

第 4 章固定已训练模型，只改变测试输入。算法稳定性则改变训练集中的一个样本，重新运行同一训练算法，再比较两个模型在同一测试点上的损失。例如，训练集 S 与 S′ 只相差一个标签，分别得到模型 A 与 B；它们对一批固定测试题的损失差，就是研究训练数据敏感性的入口。

这类分析把模型对少数训练样本的依赖与泛化联系起来。相关理论中的门数、学习率、训练步数和损失条件，需要一起带入自己的设置。实际验证可以固定初始化，替换少量训练样本，测量重新训练后的损失分布；输入舍入测试则继续用于评估部署扰动。两种实验分别定位训练过程与推理过程的敏感性。

5.11 噪声与恢复：错误样本怎样改变损失地形

5.12 手算例：同一个余弦模型，标签改变了局部曲率

取 $z(\theta)=\cos\theta$、$p=\mathrm{sigmoid}(z)$，交叉熵关于 θ 的二阶导为 $p(1-p)(z')^2+(p-y)z''$。在 $\theta=0$，$z=1$、$z'=0$、$z''=-1$、$p\approx0.731$。若标签 $y=1$，曲率约为 0.269；若 $y=0$，曲率约为 -0.731。标签改变会通过残差项改变局部地形。

这个手算例解释了为什么污染研究要比较周期参数化、振幅约束和线路结构。实验可以固定错误样本集合，观察损失、路由漂移及移除错误样本后的恢复速度，再定位哪种结构影响了恢复。相关经验结果见 数据污染与机器遗忘研究。

> 练习 **5** 在 EWC 手算例中，$F=9$、$\lambda=1/9$ 时 θ 的最优值是多少？旧任务损失 $\theta^2/2$ 与新任务损失 $(\theta-2)^2/2$ 各是多少？

6 把实际实验读成机制问题

对应原报告：第 4 节：实现与实测结果

本章使用已完成的 MoTE 实验数据：WikiText-2、两层因果语言模型、BPE4096、16 个专家、top-4、FP32、TITAN V，每项训练 4000 步，六组配置分别运行三个种子。阅读顺序是实验设置 → 指标含义 → 数值变化 → 机制解释 → 下一步验证。

6.1 先把几种 Born 实现分清楚

compact_born 用 q＝log₂E 个 qubit 的联合基态概率表示 E 个专家。amplitude_born 从实振幅编码出发，使用输入相关旋转。共享 Born 则让各 token 使用同一个可学习正交矩阵，并在推理时缓存。分块 quantum 读取的是不同 qubit 的边缘概率，再做归一化。这些结构的概率来源和计算路径不同，实验需按组件比较。

6.2 手算例：88.727 ms 到 66.998 ms 的收益怎么计算

在 batch16、context128 的整模型前向中，原 Born 的平均延迟为 88.727 ms，共享 Born 为 66.998 ms。用这两个均值估算相对减少量：(88.727−66.998)/88.727≈24.49%。原报告按每个种子配对后求平均，结果约 24.5%。

共享 U 允许推理阶段缓存算子，逐 token 的演化变成矩阵乘法。这给出了与耗时变化相对应的实现机制。训练阶段要继续更新 U 并反向传播，原报告中串行训练步耗时的改善约为 4.8%。推理与训练各自对应不同的计算账单。

6.3 CE 与 PPL 怎样互相换算

CE 是正确下一个 token 的平均负对数概率；PPL＝exp(CE)。CE 越低，模型平均给真实 token 的概率越高。比较两个模型时，PPL 比值等于 CE 差的指数，因此很小的 CE 差也可以换算成直观的相对变化。

$$\mathrm{PPL} = \exp(\mathrm{CE}), \quad \frac{\mathrm{PPL}_B}{\mathrm{PPL}_A} = \exp(\mathrm{CE}_B - \mathrm{CE}_A).$$

6.4 手算例：怎样读 79.48 ± 1.98 和 80.39 ± 2.47

half MLP 的 test PPL 是 79.48±1.98，共享 Born 是 80.39±2.47。这里 ± 后面是三个训练种子的样本标准差，描述训练重复之间的波动。共享 Born 三个种子的 PPL 都更高，配对平均相对增加 1.135%。

直接用两个均值计算 80.39/79.48−1，会得到约 1.145%。这个值与 1.135% 略有差别，来源是求平均的顺序：平均比值和均值之比通常不同。配对计算保留了同一种子下共同初始化和采样条件的对应关系。

6.5 切换率很小，为什么还值得研究

每个种子、每种扰动条件包含 16,384 个 token × 4 个 router＝65,536 次路由决策。half MLP 的局部 BF16 切换计数为 124、123、92，三种子合计 339/196,608≈0.1724%；共享 Born 为 151、152、170，合计 473/196,608≈0.2406%。

这里先把 router 输入舍入到 BF16，再转回 FP32 计算，直接测量输入表示舍入造成的变化。少量切换仍可能落在重要位置，且每次切换的专家输出差异不同。第 4 章的“频率×后果”分析因此直接适用。

6.6 如何解释边界训练的混合结果

边界训练让 MLP 的局部切换计数从 339 降为 302，合并计数降幅约为 10.9%；逐种子比值平均后的降幅约为 10.3%。完整模型传播测试中，目标 token logprob 的绝对差大于 0.1 的事件却从 42 增至 64，总样本数都是 49,152。三个种子的这类事件都增加。

数据直接指向边界目标遗漏的量：被替换专家的输出差异以及后续层的传播敏感度。下一轮可以按输出影响给边界损失加权，并同时记录切换次数和误差尾部。这是从观察到的失败走向可验证改进的一条分析链。

logprob 相差 0.1 的含义也可以计算：若 log q−log p＝0.1，则 q/p＝exp(0.1)≈1.105；若差为 −0.1，则 q/p≈0.905。这个指标衡量同一真实 token 的概率变化，不同于整段文本的正确率。评估生成任务时还要记录最终答案交付和触顶情况。

练习 **6** 一个方法 CE 比基线高 0.01，PPL 大约增加百分之几？如果三个种子共观察到 300 次切换、分母为 200,000，切换率是多少？

7 怎样设计能回答问题的实验

对应原报告：第 5 节：研究假设与实验顺序

一个有用的实验要对应一个清楚的因果问题。想研究 Born 读出，就固定编码和预算；想研究几何保护，就让各类结构使用同样保护策略；想研究推理效率，就测量相同输入形状和完整计算路径。

7.1 手算例：四组实验拆开结构收益和保护收益

教学设定中，四组模型学习新任务后，旧任务分数分别为：MLP 无保护 60，Born 无保护 62，MLP 加保护 78，Born 加保护 79。假设四组新任务分数都为 80。结构差异在无保护时为 2 分，在有保护时为 1 分；保护带来的改善分别为 18 分和 17 分。

若只比较 Born 加保护的 79 与 MLP 无保护的 60，会把结构变化和训练目标变化合在一起。四组设计把它们拆开：这组教学数据中的主要改善来自保护，结构的额外贡献较小。结构与保护的交互量为 (79−62)−(78−60)＝−1 分。

7.2 为什么要先冻结，再联合训练

冻结 backbone 与 experts 后，只有 gate 改变，便于测量结构和读出的作用。随后打开联合训练，观察 gate 是否引导其他组件形成更有效的分工。两阶段分别回答局部机制和共同适应的问题。

筛选阶段可以依次比较：MLP、相同编码器的平方振幅头、周期特征网络、实振幅 Born、复振幅 Born、共享 Born。表现较好的候选再移除重上传、相位或耦合。每一步只改变准备研究的组件。

7.3 无耦合消融为什么还要检查编码

对两个 qubit，乘积态的四个振幅可以写为 (ac, ad, bc, bd)，因此满足第一项×第四项＝第二项×第三项。一个通用编码器直接输出四个联合振幅时，通常没有施加这个关系。即使后面只使用局部旋转，输入态自身也可能包含非乘积结构。

7.4 手算例：用四个数检查一个编码是否为乘积态

振幅 (1,0,0,1)/√2 对应的 2×2 系数矩阵有非零行列式，无法分解为两个二元向量的外积。振幅 (1,1,1,1)/2 则可以写成 (1,1)/√2 与自身的张量积。设计完全无纠缠对照时，应从乘积编码开始，并使用局部操作。

7.5 旧任务保持应该怎样统计

7.6 手算例：三个任务的一条学习轨迹

假设任务 1 刚学完得分 0.80；学完任务 2 后，任务 1/2 分数为 0.70/0.75；学完任务 3 后，三项为 0.60/0.72/0.70。最终平均分为 (0.60＋0.72＋0.70)/3≈0.6733。任务 1 相对历史最高值丢失 0.20，任务 2 丢失 0.03，旧任务平均遗忘为 0.115。

持续学习应同时绘制新任务学习速度与旧任务保留。保护系数增大时，旧任务可能更稳，新任务学习也可能更慢。比较相同新任务水平下的旧任务分数，能读出这个权衡。任务顺序也要变化，例如数学→代码→通用，以及对应的其他排列。

7.7 训练种子、数据划分和预算

同一种子下共享非路由初始化、数据顺序和专家布局，可以减少与研究问题无关的波动。训练种子形成独立训练重复；一次模型产生的许多 token 用于描述该次模型的误差分布。

训练集用于更新，验证集用于选择配置与 checkpoint，测试集用于最终报告。比较同参数预算与同墙钟预算时，应分别建立实验组：一种考察给定容量下的质量，另一种考察给定时间内实际得到的模型。自然梯度还要计入矩阵估计和求解时间。

7.8 一条节省算力的执行路线

第一步用手算或小张量程序核验公式和梯度；第二步用冻结表征筛选结构；第三步对候选进行短程联合训练；第四步增加种子、任务顺序和独立验证，检验结果是否稳定。每个阶段都保留输入、配置、版本与失败记录，让下一步直接利用已有证据。

练习 7 在四组教学数据中，如果 Born 加保护的旧任务分数仍为 79，新任务分数却只有 65，而 MLP 加保护的新任务分数为 80，该怎样继续比较？

8 讨论失败机制与资源成本

对应原报告：第 6 节：结构复杂度、硬件访问条件和证据解释

8.1 更复杂的结构会付出哪些代价

增加线路深度或可训练交互，会增加表达方向、计算量和优化难度。需要同时测量三条曲线：训练损失、验证损失、梯度或 Fisher 谱。训练和验证一起改善时，新增结构可能匹配任务；训练改善而验证退化时，应检查噪声拟合和容量；梯度整体变得很弱时，应检查训练是否难以找到有效更新。

量子线路中的 barren plateau 研究分析某些条件下梯度随规模快速减小的现象；量子核集中研究分析不同样本的可用相似度变得难以区分的现象。它们分别对应“参数难以调整”和“表示难以区分输入”两类失败。对当前小态空间，直接扫描深度并记录这些量最有帮助。

8.2 参数个数相同，计算成本为什么还能差很多

一个参数可能只参与一次高效矩阵乘法，也可能进入每个 token 的多层旋转及若干中间张量。参数量描述需要存储多少可训练数值，耗时还由运算次数、内存访问、内核启动及并行利用率决定。共享 U 的推理收益就来自改变运算组织方式。

8.3 手算例：把四个 **qubit** 的模拟成本写成普通数组

4 个 qubit 对应 16 个复振幅；6 个 qubit 对应 64 个复振幅。当前 gate 的经典模拟就是在处理这些小数组及其变换。若给每个 token 构造不同算子，成本随 token 数重复；若全部 token 共用一个矩阵，可以先构造一次，再批量应用。

量子硬件上的复杂度研究还会规定样本如何被访问、允许哪些相干操作、要读取哪些结果，以及哪种资源作为计量单位。阅读“指数优势”时，先写下这些条件，再与自己的部署任务逐项对应。当前 GPU 路由的直接目标是同质量下的时间和显存，以及同时间下的模型质量。

8.4 怎样把负面结果转成下一步工作

若平方振幅头已经复现候选的收益，就优先保留简单读出并分析其梯度；若周期经典网络复现收益，就研究编码频谱；若共享矩阵降低了推理耗时，就把缓存与批量算子作为优化重点；若低切换率伴随较大输出尾部，就把专家差异纳入训练目标。每种结果都能指向一个具体的组件。

练习 8 模型 A 每步 0.2 秒，需要 1000 步达到目标质量；模型 B 每步 0.5 秒，需要 500 步。若其余开销相同，哪一个更快？如何解释 B 的优化表现？

9 读完以后，如何回到原报告

对应原报告：第 7 节：结论；附录 A：数学核验

现在可以把原报告压缩成一条有因果联系的主线：编码和演化决定输入到概率的函数，输出几何决定参数变化的影响，选择边界决定专家是否切换，专家差异和后续传播决定最终误差。持续学习再追踪这整条链怎样随新任务训练而变化。

9.1 读公式时使用同一套问题

看到一个公式，依次标出：输入是什么，可训练参数是什么，固定了哪些对象，测量了什么输出，采用了哪些局部条件。例如实态 Fisher 等价固定计算基读出，并在归一化、局部非零振幅处推导；输出误差公式固定专家输出，计算权重变化的贡献。条件直接告诉你该把公式放到实现的哪个位置。

9.2 读结果时使用同一条分析链

先写结论，例如“共享矩阵降低了推理延迟”；接着写观察到的数值和设置；再说明哪些运算被合并或缓存；最后给出能进一步检验解释的对照。负面结果也使用同一结构，例如“边界训练降低切换次数、输出尾部却增大”，随后分析专家输出差异并设计加权目标。

9.3 建议的第二遍阅读顺序

先读原报告的实际实验，明确当前最需要解决的质量与稳定性问题；再读几何部分，找到可能控制这些问题的量；接着读持续学习与编码文献，选择可实现的结构或目标；最后用实验设计章节检查基线、预算和统计单位。这样的顺序能把每个数学概念连接到一个具体决定。

完成阅读后，你应能够独立解释五件事：为什么同一概率可以有不同训练路径；实态 Fisher 等价是怎样约出来的；top-k 稳定需要间隔和敏感度共同控制；旧任务保护怎样与新任务学习形成权衡；切换次数怎样通过专家差异转化为输出风险。

10 练习答案与讲解

10.1 练习 1

三位专家仍输出 10、20、40。如果完整权重从 (0.6, 0.3, 0.1) 变为 (0.5, 0.4, 0.1)，输出改变多少？哪一项导致变化？

新输出为 5＋8＋4＝17，比原来的 16 增加 1。权重从第一位专家转移了 0.1 到第二位，因此变化为 0.1×(20−10)＝1。这个“权重转移量×专家输出差”会在第 4 章再次出现。

10.2 练习 2

p＝(0.8, 0.2) 在 α＝2 时变成什么？top-1 会改变吗？

平方得到 (0.64, 0.04)，除以 0.68 后为 (16/17, 1/17)，约为 (0.9412, 0.0588)。top-1 仍是第一项，第一项的组合权重增大。

10.3 练习 3

若 $\psi(\theta)=(\cos\theta, \sin\theta)$，在 $\theta=\pi/4$ 时计算经典 Fisher。把 θ 换成 θ＝2u 后，关于 u 的 Fisher 是多少？

$\theta=\pi/4$ 时概率为 (1/2, 1/2)，导数为 (−1, 1)，$F\theta=1/(1/2)+1/(1/2)=4$。由链式法则，关于 u 的概率导数增大 2 倍，所以 Fu＝16。参数坐标改变会改变 Fisher 的数值；对应的二次型满足 $F\theta(d\theta)^2=Fu(du)^2$。

10.4 练习 4

路由 A 在 1000 个样本中发生 20 次切换，每次输出变化为 0.2；路由 B 发生 2 次切换，每次变化为 3。只统计这些切换贡献时，哪一个平均平方误差更小？

A 的平均平方误差为 $20\times0.2^2/1000=0.0008$。B 为 $2\times3^2/1000=0.018$。A 的切换更多，输出误差更小。选择稳定性应与切换后果联合分析。

10.5 练习 5

在 EWC 手算例中，F＝9、λ＝1/9 时 θ 的最优值是多少？旧任务损失 $\theta^2/2$ 与新任务损失 $(\theta-2)^2/2$ 各是多少？

λF＝1，故 θ＝2/(1＋1)＝1。两项任务损失均为 0.5。与 λ＝0、λ＝1 的情况一起画出三个点，就能看到保护强度控制的新旧任务折中。

10.6 练习 6

一个方法 CE 比基线高 0.01，PPL 大约增加百分之几？如果三个种子共观察到 300 次切换、分母为 200,000，切换率是多少？

PPL 相对增加 $\exp(0.01)-1\approx1.005\%$。切换率为 300/200000＝0.0015＝0.15%。前者描述任务预测质量，后者描述指定条件下的路由行为，两项需要同时报告。

10.7 练习 7

在四组教学数据中，如果 Born 加保护的旧任务分数仍为 79，新任务分数却只有 65，而 MLP 加保护的新任务分数为 80，该怎样继续比较？

扫描双方的保护强度，绘制旧任务分数对新任务分数的曲线。在新任务分数相近的位置比较旧任务保持，并记录达到该位置的时间。这样可以判断多出的旧任务保持来自更好的权衡，还是较弱的新任务学习。

10.8 练习 8

模型 A 每步 0.2 秒，需要 1000 步达到目标质量；模型 B 每步 0.5 秒，需要 500 步。若其余开销相同，哪一个更快？如何解释 B 的优化表现？

A 用 200 秒，B 用 250 秒。B 达到目标所需更新步数更少，单步计算更贵；在这个预算下 A 的墙钟效率更好。报告应同时给出步数和总耗时。

11 延伸阅读

配套原报告。QuantumGate 研究综述 按研究问题组织证据；完整文献索引 收录 26 篇一手来源。教学例题和练习答案由本讲义构造，第 6 章实测数字来自 outputs/routing_stability_round1/REPORT_zh.md。

先读持续学习。 Quantum Continual Learning Overcoming Catastrophic Forgetting 与 经典 EWC。带着第 5 章的单参数例子，寻找论文中的重要性估计、旧样本使用方式和任务顺序。

再读编码。 Effect of data encoding on the expressive power of variational quantum-machine-learning models。用两次 RY 的手算例理解输入频率怎样进入函数。

随后读几何优化。 Quantum Natural Gradient 和 数据相关量子 Fisher。重点关注度量如何计算、哪些方向活跃、求解成本怎样估计。

最后读基准与失败机制。QML 基准比较、成本函数与 barren plateau、量子核集中。按数据、编码、优化器、预算和任务指标五项整理每个实验。

噪声恢复方向。 数据污染与机器遗忘研究。结合余弦曲率例子，区分作者的实验观察、机制解释以及需要增加的经典对照。