Qwen 基模上的 MoTE 联合训练：跨机器交接方案

2026-10-30 | 发布分支 mote-quantum | 已有实验归档与下一阶段执行安排

主要决定：让路由与专家在真实任务中共同形成分工

下一阶段以预训练 Qwen 为起点，替换部分 FFN 为 MoTE，让 gate、专家和转换余项从首个任务更新共同学习。主要问题是：QuantumGate 能否组织出更有用的专家分工，并在任务成绩、实际计算成本与路由稳定性之间取得更好的组合。

首轮由本地 PRO 4000 打通 0.6B，实验室 A800 承担 1.7B 的正式比较，4B 用于后续规模复核。双 V100 负责 FP16 独立复核；海光 BW1000 先完成厂商软件栈迁移与相同模型的短测。每种硬件形成完整的配对实验，跨精度或跨软件栈的结果单独分析。

本次发布包含已有代码、报告、图表、紧凑原始结果、审计记录和执行任务书。Qwen 接入四种新路由的实现被明确交给下一阶段；正式训练尚未启动。各机器现在可以先开展环境检查、数学测试、模型准备及分配的实现工作。

已有证据如何指导这次设计

前面的真实小模型训练已经验证了路由实现可训练。稳定性实验给出的工程收益是混合的，强 margin 曾产生固定专家集合，因此本阶段先采用共同的任务损失和负载规则，观察分工的自然形成。

功能几何实验进一步发现：对真正参与稀疏混合的权重进行适配，能改善模型功能保留；CZ 门从专家输出尺度中获得收益，对角控制几乎取得相同效果。这把后续研究重点引向各专家的真实作用、选择边界以及它们随训练的共同演化。模型 Fisher 的交叉项在当前实验中没有稳定额外收益，首轮联合训练将其保留为诊断量。

交错 CZ 与乘积态对照的局部可达方向存在差别，稀疏 top-k 还会进一步限制这些方向。我们将跟踪这些差别是否影响任务学习。经典 teacher 的模仿能力是已有结构的诊断；新的任务比较允许 QuantumGate 形成另一套高效的专家组织。

静态专家排列扩展被拒绝、效用预测的阴性结果，以及一次选择器协议错误和纠正后的重放，都保存在本次证据包。最新功能报告与补充材料提供结论和逐 seed 数据；交接首页列出了阅读顺序。

公平比较的共同协议

主比较保留 MLP、经典 affine Born、交错 CZ 和匹配乘积态四组。CZ 与乘积态采用相同编码和参数形状，差别落在 CZ 连接。另保留原始 Dense 模型评价，以及相同层范围的 Dense FFN 继续训练控制。

同一种子内，四门从同一份预训练模型转换得到的专家状态出发，使用相同数据次序和监督 token 预算。初始专家之间保持独立。首轮更新最后四分之一层中的 MoTE 专家、gate 与转换余项，固定其余预训练权重；Dense 训练控制更新对应的原 FFN。所有参数范围、实际参数量和初始替换误差都要保存。

主目标采用 next-token 交叉熵和统一负载项。新协议把 gate_freeze_steps 设为零，teacher 蒸馏、margin 和功能几何附加损失设为零，路由温度固定。旧入口中的阶段训练、数据混合和冻结默认值必须显式核对。新协议 JSON 是研究设计，执行者需要据此生成经过验证的训练配置。

数据按原始文档身份先划分 train、内部 dev 和保留 test，再分词和打包；共同冻结文档清单、模型版本、tokenizer 与采样顺序。初步语料方案是 FineWeb 的有界子集，最终来源、许可和版本在 DATA_RELEASE 中确定。旧研究已经观察过的 validation 只提供背景信息。训练配置和 checkpoint 规则在内部 dev 上确定，保留 test 在整个矩阵锁定后统一评价。

正式主结果使用相同 token 预算的最终 checkpoint，内部 dev 选出的最佳 checkpoint 作为另一项结果。每种结构保留三个种子，逐 seed 配对差、跨 seed 标准差与区间分别报告。等时间成绩、实际吞吐和显存同时记录。少量有害切换事件用计数和误差尾部解释，功能分工用实际专家替换代价检验。

各机器的任务与依赖

PRO 4000：负责共享代码接入和 **0.6B** 验证。新代码放在独立的 Qwen 实验目录；把诊断代码的 cost 输出正确转换成生产路由的 logits，检查 top-k、梯度、精度和模型保存。随后准备共同数据版本，完成全部结构和 Dense 控制的短测，发布带精确命令的集成验收文件。其他机器使用这个冻结版本运行正式矩阵。

双 **V100**：负责独立 **FP16** 复核。优先让两张卡各自运行完整方法集合中的不同种子。维持相同的有效 token 更新数，记录梯度缩放和跳过更新。若显存需要多卡分片，建立单独配置并验证与单卡的更新一致性。

A800：负责 **1.7B** 正式实验。先准备模型和环境，集成版本就绪后依次完成全部方法的短测，再冻结共同正式预算。正式矩阵为四门与 Dense 控制、各三个种子。根据预定 checkpoint 检查路由曝光、专家更新、功能替换风险及稳定性，并提交阶段报告。4B 先测真实显存与吞吐，再安排独立矩阵。

BW1000：负责海光 **DTK** 兼容性与成本验证。保留厂商适配版 PyTorch，对旋转、CZ、概率、索引 dispatch、注意力和反向传播逐项核验。通过后在相同 0.6B 模型与数据上完成共同短测；正式扩展保持自己的完整硬件 cohort。

各机器的计划、输出位置和给执行代理的任务书分别位于 plans 与 agents 目录。PRO 4000 是共享接入代码负责人，其他机器的兼容性修复用各自分支提交整合。所有运行记录精确 commit、配置哈希与环境；正在运行的配置保持冻结。

核验、预算与交付

每个正式运行前都核对共享专家起点、样本顺序、实际稀疏执行，以及 gate 和专家的非零梯度与参数更新。checkpoint 保存模型、优化器、调度器、scaler、随机状态和数据游标，并以中断恢复对照检验续训。失败现场和重试采用不同目录。

共同配置给出首轮有限继续训练预算。各机先测短程实际吞吐和费用，再记录完整矩阵所需 GPU 小时；预算调整应生成统一的新配置，适用于整个比较。已有硬件和实验室额度优先，个人新增租赁另作资源决定。

证据包按原始路径复制 CSV、JSON 和曲线记录，并逐文件核对 SHA-256。大模型权重、历史 checkpoint、数组缓存和数据集保留在原位置，在 EXTERNAL_ARTIFACTS 中列明。新机器拉取后可阅读全部已发布报告和紧凑证据；新 Qwen 训练需要另行取得模型及共同数据，旧 checkpoint 重放需要转移相应原始资产。

下一次审校先验收四门接入、数据冻结与共同 pilot，再查看正式联合训练。报告正文依次给出任务结果、关键机制和成本取舍，逐 seed 数字、参数、采样与原始明细放入补充材料。每阶段交付 Markdown、Typst 和逐页核验的 PDF，中文使用楷体，英文使用 Times New Roman。